

面向智慧城市社交网络中网络欺凌识别与检测的多模态城市级方法：项目提案

GUO、TIAN、WANG、WEN、ZHU

CDS553：智慧城市项目

岭南大学

2026 年 2 月

摘要

网络欺凌可以通过智慧城市中使用的数字渠道迅速传播，例如社区论坛、服务应用反馈帖子以及公开社交媒体。纯文本检测器已有所改进，但实际内容审核仍面临三个常见问题。首先，欺凌线索往往取决于谁在与谁交流，以及话题如何发展。其次，有害内容较为罕见，因此数据存在严重的类别不平衡问题。第三，许多帖子混合了文本、图像和短视频。在本项目中，我们构建了一个实用的多模态处理流程，结合文本、话题和用户会话上下文、Instagram 图像，以及由少量采样关键帧表示的 Vine 视频。我们将经典基线（如 TF-IDF 结合线性模型）与 Transformer 基线（如 BERT 和 RoBERTa）进行比较，然后评估将文本与上下文嵌入以及由预训练模型（如 CLIP）提取的视觉嵌入相结合的简单融合模型。为保持在合理的课程计算资源预算之内，我们对大型编码器进行冻结、缓存嵌入，并仅训练小型融合层和分类层。我们报告宏观 F1 和 AUPRC，以及按模态划分的消融实验、校准与操作点分析，以及一项符合内容审核需求的简短错误分析。

Keywords: 网络欺凌检测，智慧城市，多模态学习，Transformer，可复现性，鲁棒性

面向智慧城市社交网络中网络欺凌识别与检测的多模态城市级方法：项目提案

引言与动机

智慧城市基础设施越来越依赖数字平台——如社区报告应用、公共服务反馈渠道和城市级讨论论坛——来支持居民参与和公民互动。当居民通过这些渠道报告社区问题、对公共服务发表评论或进行日常交流时，这些支撑公民生活的开放平台同样可能成为有针对性骚扰和网络欺凌的发生场所。若不加以处理，此类内容可能打击居民参与积极性，损害智慧城市系统本应建立的公众信任。

自动化检测是一个切实可行的第一步：其目的不是取代人工判断，而是在有害内容传播之前，通过自动标记帮助内容审核团队进行审查。实际上，城市级平台必须服务至少三类不同群体：**市民或受害者**——需要评估和记录针对自身的潜在骚扰；**内容发布者**——可从提交前的自我检查中获益，避免无意造成伤害；以及**平台版主**——负责对已标记内容进行分类，并在机构问责框架下做出最终决定。这种“人在回路”（human-in-the-loop）结构意味着分类器的作用不是作出裁决，而是提供风险评分和支持证据，供人工审核人员采取行动。在这一背景下，整体准确率并非最有用的衡量指标——一个仅凭将所有内容标记为无害便能达到 90% 准确率的分类器，对内容审核毫无用处。更重要的是系统能否可靠地识别少数类型的骚扰内容，能否在城市级平台的不同社区群体之间保持一致性，以及其置信度评分是否具有足够意义，可用于设定审核阈值。

上述问题指向推动本工作的三项具体挑战 [5.]。公民平台中的用户生成文本往往非正式且具有社区特色：俚语、地方性表达和平台惯例在不同区域间差异显著，这意味着在某一社区数据上训练的模型，在另一社区上的表现可能大幅下降。有害内容相对稀少，这导致标准训练目标在训练和评估中均倾向于低估少数类别的骚扰类型。最后，文本本身并不总能清晰表达意图——同一句话在一个话题中可能无害，在另一个话题中则可能构成有针对性的攻击，具体取决于涉及的人物及其周围的上下文。最后这一点表明，引入非文本信号——如时间信息、互动结构和用户级元数据——可能在纯文本不足的情况下提升检测效果 [13.]。

问题陈述

我们的目标是构建一个既可问责又感知上下文的城市级网络欺凌检测工作流程。我们对各模型族采用一致的评估标准，并纳入原始文本之外的信号。我们将该工作流程原型化为 **CitySafe** 试点应用。为满足隐私优先的约束条件，CitySafe 包含一个**本地证据工具包**，默认将分析记录存储在用户设备上，并要求在任何内容上传或与版主共享之前获得用户的明确同意。

两项治理原则从一开始便约束着设计方向。第一，**人在回路**：分类器输出作为辅助证据，例如风险评分、支持性上下文和各类别置信度，而非自动裁决。最终决定权仍由人工审核人员掌握，因此模型应产生校准良好的置信度评分，而不仅仅是二元标签。第二，

隐私优先：可部署的系统应最大限度地减少数据留存，在任何内容对外共享之前支持用户的明确同意，并仅使用每个用例所需的最少信息，例如以粗粒度区域元数据代替精确位置。这些约束影响了我们的评估优先级。校准和阈值选择是一等指标，而非事后补充。我们关注面向审核的操作点，即类别不平衡下召回率与精确率之间的权衡，而非汇总准确率。

在本提案中，我们以宽泛且实用的方式使用“多模态”一词。它意味着我们结合了内容审核系统可合理获取的不同类型证据。文本始终存在，我们同时使用话题或用户会话上下文。当帖子关联了媒体内容时，我们从图像和少量采样视频帧中添加冻结的视觉特征。音频被视为可选项，仅当我们能够可靠地从视频文件中提取音轨时才使用。这更接近于特征增强的文本分类，而非完整的端到端多模态建模，但它符合我们的数据集和计算资源预算，同时仍然允许我们在实践中测试额外信号是否有所帮助 [13.]。

具体而言，所有模型将以文本作为输入，我们提出的系统还将使用从数据集中提取的上下文信号：

- **结构化上下文信号：**帖子级元数据，如时间戳分箱、平台或频道标识符，以及简单的互动统计数据（如回复数和提及密度），前提是数据集提供这些信息。
- **扩展信号：**跨平台链接标识符（如 URL 或媒体 ID），以及从回复或提及边缘导出的简单对话图统计数据。

这种框架反映了骚扰在实践中的运作方式：同样的话语在不同的上下文、时间和互动历史背景下承载着不同的风险。

目标与研究问题

目标

1. 构建一个可复现的、从数据到指标的网络欺凌检测流程，适用于智慧城市内容审核。该工作流程以隐私为先，并支持人工审核。
2. 使用相同的数据集划分、固定的调参预算和相同的评估指标，建立强基线——包括经典机器学习模型和 Transformer 文本模型。
3. 逐步衡量逐步添加额外信号后的收益：文本 → + 上下文 → + 图像 → + 视频关键帧。媒体实验在关联子集上运行，我们报告其划分统计数据。
4. 构建并测试一个融合模型，该模型在部分模态缺失和类别不平衡的情况下仍能正常工作，同时保持在 Google Colab 或一张消费级 GPU（如 RTX 3070 或 RTX 4060）的计算范围内。
5. 以透明方式报告结果，包括消融表格、效率说明、校准检查，以及对最重要比较的配对显著性检验。

研究问题

1. 在同一受控协议下，经典机器学习基线与 Transformer 基线相比表现如何？性能提升中有多少来自添加上下文和媒体信号，而非仅升级文本编码器？
2. 在包含媒体的关联子集上，与纯文本及文本 + 上下文模型相比，图像和视频关键帧是否能提高有害内容的召回率，并改善宏观指标（如宏观 F1 和 AUPRC）？
3. 模型在不同平台子集之间的迁移能力如何？当写作风格和话题发生变化时，简单的鲁棒性措施——如感知不平衡的训练以及小预算的领域自适应预训练步骤——是否有所帮助？

相关工作

网络欺凌检测的综述研究表明，该领域已有大量研究积累，但不同研究之间的评估方法差异较大，难以进行直接比较；可复现性和数据稀缺仍是普遍存在的问题 [4.][5.]。预训练 Transformer——尤其是 BERT [1.] 和 RoBERTa [9.]——已成为分类任务的标准文本编码器，并为迁移学习提供了强基线；然而，在基准测试上较高的准确率并不总意味着在数据分布发生变化时具有更好的鲁棒性 [13.]。近期部分研究也测试了指令微调大语言模型在仇恨言论和网络欺凌检测方面的表现，结果喜忧参半：零样本性能在格式规范的文本上尚可，但在非正式或代码混用语言上往往大幅下降，而此类语言在公民平台上十分常见 [14.]。

然而，需要指出的是，多模态融合并不自动保证性能提升。在许多数据集中，文本本身已能解释大部分标签，而标签噪声可能掩盖细微的改进效果。视觉特征也可能诱导捷径学习，例如某种表情包模板在某一子集中与某个类别相关，但在另一子集中并不相关。因此，我们将视觉模态的贡献视为一个实证问题，并通过系统性消融实验和错误分析同时报告改进和失败模式。

领域自适应预训练（DAPT）在任务微调之前对领域内文本继续进行掩码语言模型训练，是一种可减少词汇和风格不匹配的实用方法 [6.]。对于类别不平衡问题，焦点式损失重加权已被证明能使模型更关注较难的、代表性不足的样本 [8.]。最后，在 NLP 基准上比较模型时，建议进行显著性检验，因为宏观指标的差异往往小于表面所呈现的幅度 [3.]；我们在评估计划中采用这一做法。

拟议方法论

数据集与数据准备

我们将使用一个包含用户会话及帖子或评论文本的多平台网络欺凌数据集，以及一个关联媒体资产的子集 [11.]。所提供文件夹中的媒体清单包括 **2,263 张** .jpg 格式图像和 **983 段** .mp4 格式短视频。大部分媒体来源于 Instagram 图像和 Vine 短视频。

文本及会话/上下文文件以特定平台的用户或会话记录形式存储，例如“common users”和“normal users”。已为监督学习提供带标注的子集。

目标标签。为保持比较的简洁性，我们主要报告二元设置：有害或网络欺凌 vs. 无害。我们将记录从原始标签到该二元标签的映射方式。若某子集支持更细粒度的标签（如角色、类型或目标），我们将其视为次级实验并单独报告。

文本与媒体的关联。当帖子或会话标识符存在时，我们通过匹配元数据文件和媒体文件名中共享的 ID，将每条文本记录与其图像或视频关联起来。若关联不完整，我们仍对所有记录运行文本 + 上下文流程，并仅在关联子集上运行图像和视频实验。我们报告关联子集的大小及其划分统计数据，以便读者公正地解读结果。

视频最小可行产品（MVP）的关键帧提取。我们保持视频建模的简洁性。对于每段 Vine 视频，我们从视频中均匀采样少量帧，初始设定为 $K = 8$ 或 16 帧。我们独立对每帧进行编码，然后通过均值池化或最大值池化对帧向量进行汇聚，得到一个视频表示。

音频信号。音频在本项目中为可选项。短时社交视频不总是具有干净的音轨，提取质量可能参差不齐。我们仅在能够可靠地从相当比例的视频中提取音频时才使用音频特征，并将报告覆盖率。若音频覆盖率较低，则将音频保留为未来工作方向。

标注质量检查。网络欺凌标签可能具有主观性。我们将通过对 200–300 个随机样本进行双重核查，开展小规模质量审计。两名团队成员将遵循简短的标注指南，我们将使用 Cohen κ 报告标注者间一致性，并附上对常见分歧的简要说明。

数据划分与防泄漏控制。我们采用 70/10/20 的比例进行分层训练集、验证集和测试集划分，并使用固定随机种子。当会话级标识符存在时，划分在会话或用户层面进行，以避免近重复样本在各划分之间泄漏。

系统概览与模型流程：图 1

图 1 展示了端到端的处理流程。所有大型编码器均作为冻结特征提取器使用；在我们的核心实验中，仅训练小型融合层和分类层。




图 1

多模态处理流程。文本和上下文是核心输入。图像和视频关键帧作为冻结视觉特征在关联子集上添加。音频为可选项，仅在能可靠提取时使用。

基线模型

我们在一套统一的协议下对具有代表性的基线进行基准测试：

1. **经典机器学习**：在含词级和字符级 n-gram 的 TF-IDF 特征上使用逻辑回归和线性 SVM。
2. **Transformer 文本模型**：带标准分类头的微调 BERT 和 RoBERTa。
3. **文本 + 上下文融合**：将文本表示（TF-IDF 或池化的 Transformer 嵌入）与工程化的上下文特征拼接，然后训练一个 MLP。
4. **文本 + 视觉融合**：添加来自 CLIP 或 ViT 的冻结视觉嵌入，比较概率后期融合与特征拼接的效果。

我们的模型与拟议改进

我们提出的模型保持架构简洁，但针对实际部署问题：

- a) **鲁棒融合**：带模态丢弃的门控融合。我们在训练期间随机屏蔽一个模态，使模型在测试时某些图像或视频缺失的情况下仍保持稳定。

b) **感知不平衡的学习**：类别加权损失以及在验证集精确率-召回率曲线上进行阈值选择。我们追踪有害类别的召回率和宏观 F1[8.]。

c) **效率优先的训练**：冻结大型编码器并缓存嵌入；仅训练小型融合层和分类头。

作为可选扩展，我们可能尝试对文本编码器进行小预算的持续预训练，通常称为领域自适应预训练（DAPT）[6.]。

训练协议与计算资源预算

所有实验将在 **Google Colab** 或一张消费级 GPU（通常为 RTX 3070 或 RTX 4060）上运行。我们为学生团队保持训练方案简洁且切实可行。

对于 **Transformer 文本基线**，我们以小型固定预算和早停策略微调 BERT 或 RoBERTa。对于**多模态融合**，我们冻结大型编码器并将其嵌入缓存到磁盘，从而将训练简化为仅训练小型融合层和分类头。

为保持在显存限制之内，我们使用混合精度训练和小批次大小。若有需要，我们使用梯度累积在不超过显存的情况下达到有效批次大小。典型设置为批次大小在 8 到 32 之间（取决于文本长度），目标在 RTX 3070 或 RTX 4060 级别 GPU 上使用 8–12GB 显存。我们还将超参数搜索限定在学习率、批次大小和融合类型的小型网格范围内。出于可行性考虑，我们报告主要运行的训练时间和峰值 GPU 显存占用。

在推理阶段，我们在相同的计算资源限制下保持面向用户的路径响应灵敏。文本和图像可以在几秒内同步处理，而视频关键帧提取和评分可以路由到异步任务队列，以避免超时并平滑 GPU 使用。

评估计划

主要指标。对所有模型，我们报告宏观 F1、各类别精确率和召回率，以及 AUPRC[4.]。由于有害内容较为稀少，我们特别关注有害类别的召回率和宏观级别指标。

阈值选择与操作点。我们在验证集上使用精确率-召回率曲线选择阈值。我们不采用单一固定阈值，而是报告几个现实操作点。对于面向市民的自查功能，我们追求较高精确率以避免过多误报。对于版主审核队列，我们可以优先保证召回率，因为人工负责最终确认。

消融实验。我们进行逐步比较：纯文本、文本加上下文、再添加图像、最后在关联子集上添加视频关键帧。我们同时比较融合方案的选择，包括后期融合、特征拼接和门控融合。

额外检查。我们进行校准检查（如预期校准误差 ECE 和可靠性图），以确保置信度评分对阈值选择具有实际意义。对于关键比较，我们运行配对显著性检验 [3.]。我们还提供简短的错误分析，重点关注常见失败案例，如讽刺、依赖上下文的定向攻击、表情包式图像，以及模态缺失的输入。

项目时间表与工作分配

项目遵循从 2026 年 1 月 9 日开始的 15 周进度安排，与课程要求保持一致。详细阶段和交付成果见表 1，并在图 2中进行可视化展示。

表 1
项目日程（2026 年 1 月 9 日 – 5 月 3 日）

周次	日期范围	主要任务	交付成果
1–2	1 月 9 日 – 1 月 26 日	组建团队、确认选题、明确研究范围。	选题确认表、工作分配计划。
3–5	1 月 27 日 – 2 月 16 日	文献综述；数据集获取与清点；数据清洗；起草标注指南及试标注。	文献综述笔记、数据清单、标注指南 v1。
6–8	2 月 17 日 – 3 月 8 日	提案起草与修订；完善方法论、伦理及评估计划；内部同行评审与最终修改。	最终提案，占总成绩 30%。
9–10	3 月 9 日 – 3 月 22 日	特征工程与基线建立；训练经典模型（逻辑回归与 SVM）；建立实验追踪与报告体系。	基线模型文件、训练日志/报告。
11–12	3 月 23 日 – 4 月 5 日	微调 Transformer 基线（BERT 和 RoBERTa）；在关联媒体子集上运行初步多模态融合；在 GPU 上进行小规模超参数调整。	Transformer 模型、融合检查点、阶段性对比表。
13	4 月 6 日 – 4 月 12 日	完整评估与消融实验；错误分析；伦理/合规检查；最终报告撰写与润色；Turnitin 查重。	最终项目报告，占总成绩 50%。
14–15	4 月 13 日 – 5 月 3 日	准备演示文稿与排练；完成打包、文档整理与归档。	演示 PPT、归档项目资产，占总成绩 20%。




图 2
项目生命周期甘特图，从启动到最终演示。

工作分配

本项目由来自智慧城市技术与应用理学硕士课程（MScSCTA）的五名学生共同完成。我们按技术模块划分工作，但仍相互交叉审查代码和撰写内容。总体而言，虽然每位成员主导特定的技术模块，但整个团队共同参与代码审查和最终论文撰写。

- **数据预处理与基线 – ZHU:** 构建数据工作流，包括去重、标准化、分层划分和标签映射。实现经典机器学习基线——TF-IDF 结合逻辑回归和线性 SVM，为后续实验提供第一个参考基准点。
- **Transformer 建模与调优 – TIAN:** 在共享协议下微调 BERT 和 RoBERTa。保存训练日志和说明，以便能够在不同模型族之间进行公正的运行比较。
- **上下文特征与数据关联 – GUO:** 提取非文本线索，例如时间戳分箱、回复/提及统计，以及在可获取时提取 URL 或媒体关联标识符。确保这些特征以一致的格式用于融合模型。
- **评估与鲁棒性 – WANG:** 实现评估脚本，包括宏观 F1、AUPRC 曲线、混淆矩阵，以及有害类别召回率追踪。跨平台子集进行鲁棒性检查，并审查校准输出结果。
- **可复现性与版本管理 – WEN:** 维护共享代码库和文件结构。强制执行固定随机种子和配置日志记录，以确保主要结果可从有记录的步骤中重新运行。

预期成果

我们预计将交付：

1. 一个带有文档化标签映射的清洗数据集划分，以及含脚本和配置文件的可复现训练流程。
2. 一份基准报告，对比纯文本基线（经典机器学习和 Transformer）与添加上下文、图像和视频关键帧的多模态变体。
3. 一个使用门控融合和模态丢弃的高效多模态融合模型，以及展示各模态贡献的消融研究。
4. 一份评估摘要，包括宏观 F1/AUPRC、校准与阈值选择，以及附有代表性假阳性/假阴性的简短错误分析。
5. 一份简短的标注质量审计报告。我们在小规模双重核查样本上报告 Cohen κ ，并讨论常见的模糊案例。
6. 对伦理局限性的简要讨论：已知失败模式（例如某些语言风格的假阳性率偏高）、自动化内容审核对受影响用户的风险，以及关于“人在回路”监督的建议。

风险与缓解措施

- **类别不平衡与少数类别指标不稳定**：报告宏观 F1 和 AUPRC；在验证数据上调整操作阈值，并讨论面向内容审核的高召回率设置。
- **文本-媒体关联不完整**：对全量记录运行文本 + 上下文实验；仅在关联子集上运行视觉/视频实验，并透明地报告子集大小和划分统计数据。
- **主观标签**：进行小规模双重核查抽样并报告 Cohen κ ；在审计期间设置“模糊”类别以记录边界案例。
- **计算约束与运营成本**：我们在 Colab 或 RTX 3070/RTX 4060 级别的单张 GPU 上运行。我们冻结编码器、缓存嵌入、使用混合精度和梯度累积，并保持超参数搜索范围较小。关于部署可行性，我们还提出简单的成本与滥用控制措施，包括通过内容哈希缓存避免对相同病毒式传播内容的重复评估，以及在 API 网关处实施用户速率限制。我们报告主要运行的效率情况。
- **数据隐私与伦理使用**：所有实验均使用具有文档化使用条款的公开研究数据集。除原始数据文件中已提供的信息外，不会留存任何个人可识别信息。模型输出不会用于对个人进行画像或定向；该系统旨在辅助而非取代人工内容审核判断。

未来工作与扩展目标

我们优先构建一个在课程时限内可复现且可行的核心系统。我们同时列出若干扩展目标，这些目标将使原型更接近端到端的多模态内容审核系统。我们承认，这些扩展将引入架构复杂性，尤其在数据集标签存在噪声时，可能产生收益递减的效果。

- **视频自适应帧选择：**均匀关键帧采样是对完整视频理解的粗糙替代。一种计算高效的升级方案是按视频自适应地选择帧，仅在模型仍不确定时处理更多帧。例如，AdaFrame 通过学习决定下一步观察哪一帧及何时停止，在降低冗余计算的同时保持识别质量 [12.]。相关方向是先进行镜头或场景分割，再对片段进行时序建模，这可以捕捉时间信息，但通常需要更干净的标签和更高的计算资源。
- **音频线索（覆盖率良好时）：**若能可靠地提取音频，我们可以添加自动语音识别转录、韵律特征和音频事件嵌入。当骚扰通过语音表达、音调暗示或背景声音传递时，这些线索可能有所帮助。
- **跨模态注意力：**我们可以使用跨模态注意力机制将词语与帧或音频片段对齐，而非简单的特征融合。这种方式更灵活，但计算成本也更高，且对数据量更为敏感。

结论

本提案为智慧城市风格的数字平台建立了一项网络欺凌检测研究。我们的目标是在一套统一协议下进行受控比较，并以能够支持实际内容审核决策的形式报告结果。我们将评估经典机器学习基线、Transformer 文本模型，以及添加话题和用户上下文以及图像和视频关键帧媒体特征的融合模型。通过冻结大型编码器、缓存嵌入，以及仅训练小型融合层和分类层，我们将计算方案保持在适合学生团队的现实范围内。

我们也不预设多模态一定更优。文本通常携带大部分信号，额外模态可能引入噪声或学习捷径。在我们看来，图像和视频帧最有可能在文本模糊、带有讽刺意味或依赖表情包的帖子上发挥作用。若视觉特征在某些子集上没有帮助，我们将如实报告，并通过消融实验和错误分析加以解释。

最后，我们将系统构建围绕城市平台中的真实部署角色展开。市民可能需要谨慎的自查功能，内容发布者可能从发帖前的反馈中获益，版主则需要一个具有清晰优先级的审核队列。这正是我们关注操作点和校准，而不仅仅是准确率的原因。一个具有诚实置信度评分和合理阈值的模型，通常比宏观 F1 略高但行为不稳定的模型更为实用。

参考文献

1. Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL-HLT*.
2. Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., & Houlsby, N. (2021). An image is worth 16×16 words: Transformers for image recognition at scale. In *Proceedings of ICLR*.
3. Dror, R., Baumer, G., Shlomov, S., & Reichart, R. (2018). The Hitchhiker’s guide to testing statistical significance in natural language processing. In *Proceedings of ACL*.
4. Elsafoury, F., Salama, M., & Elaziz, M. A. (2021). When the timeline meets the pipeline: A survey on automated cyberbullying detection. *IEEE Access*, 9, 103541–103562.
5. Emmery, C., Verhoeven, B., De Pauw, G., Daelemans, W., & Hoste, V. (2021). Current limitations in cyberbullying detection: On evaluation criteria, reproducibility, and data scarcity. *Language Resources and Evaluation*, 55, 1301–1338.
6. Gururangan, S., Marasović, A., Swayamdipta, S., Lo, K., Beltagy, I., Downey, D., & Smith, N. A. (2020). Don’t stop pretraining: Adapt language models to domains and tasks. In *Proceedings of ACL*.
7. Hershey, S., Chaudhuri, S., Ellis, D. P. W., Gemmeke, J. F., Jansen, A., Moore, R. C., Plakal, M., Platt, D., Saurous, R. A., Seybold, B., Slaney, M., Weiss, R., & Wilson, K. (2017). CNN architectures for large-scale audio classification. In *Proceedings of ICASSP*.
8. Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal loss for dense object detection. In *Proceedings of ICCV*.
9. Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L., & Stoyanov, V. (2019). RoBERTa: A robustly optimized BERT pretraining approach. arXiv preprint arXiv:1907.11692.
10. Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J., Krueger, G., & Sutskever, I. (2021). Learning transferable visual models from natural language supervision. In *Proceedings of ICML*.

11. Van Bruwaene, D., Huang, Q., & Inkpen, D. (2020). A multi-platform dataset for detecting cyberbullying in social media. *Language Resources and Evaluation*, 54(4), 851–874. <https://doi.org/10.1007/s10579-020-09488-3>.
12. Wu, Z., Xiong, C., Ma, C.-Y., Socher, R., & Davis, L. S. (2019). AdaFrame: Adaptive frame selection for fast video recognition. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*.
13. Yi, P., & Zubiaga, A. (2023). Session-based cyberbullying detection in social media: A survey. *Online Social Networks and Media*, 36, 100250. <https://doi.org/10.1016/j.osnem.2023.100250>.
14. Ziems, C., Held, W., Shaikh, O., Chen, J., Zhang, Z., & Yang, D. (2024). Can large language models transform computational social science? *Computational Linguistics*, 50(1), 237–291. https://doi.org/10.1162/coli_a_00502.