

智慧城市中的网络霸凌检测：项目开题报告

项目小组

CDS553: 智慧城市项目课程

Lingnan University

2026 年 4 月

摘要

网络霸凌正日益渗透到数字公共生活中。在智慧城市生态系统中，市民依赖在线平台获取日常服务并进行交流，网络霸凌可能会破坏社会福祉。本项目提出建立一个专为智慧城市语境设计的、可复现的文本网络霸凌检测流程，以应对该场景下常见的数据规模大、话题漂移 (topic drift) 和类别不平衡等问题。我们将对一组统一的基线模型进行基准测试，其中包括经典机器学习分类器和在霸凌数据上微调过的现代 Transformer 编码器。在此基础上，我们提出了我们的改进模型：一个语境增强的 Transformer，它融合了领域自适应预训练 (Domain-Adaptive Pretraining) 和类别不平衡感知学习 (Imbalance-Aware Learning)，以提高模型的鲁棒性和泛化能力。除了基本的准确率报告外，我们还将使用 Macro/Weighted F1、AUROC/AUPRC、校准度 (Calibration)、统计显著性检验以及针对性的错误分析来进行评估。最终交付成果包括一份完整的 PDF 提案、一个可复现的代码仓库，以及一份记录模型在模拟智慧城市部署约束下的性能、效率和可靠性的实验报告。

智慧城市中的网络霸凌检测：项目开题报告

引言与动机 (Introduction and Motivation)

智慧城市服务高度依赖大规模的在线互动（例如社区群组、公共反馈平台和服务类 App）。在这些空间中，网络霸凌和骚扰言论能够迅速传播，不仅伤害个人，也会损害公众信任。因此，自动检测技术对于早期的风险筛查和支持人工审核流程至关重要。

在实践中，网络霸凌检测面临至少三个挑战。首先，用户生成内容（UGC）通常是非正式的，常包含讽刺、语码混用（code-mixing）和快速更迭的俚语。其次，标签通常高度不平衡：“非霸凌”内容占主导地位，而特定类型的霸凌样本非常稀少。第三，由于数据集在平台风格、标注策略和时间跨度上的差异，报告的结果往往难以泛化。近期的综述研究强调，跨数据集测试时性能往往会下降，且评估标准并不总是可比的 [[1]]。一项针对局限性的专门分析也指出，可复现性差距和数据稀缺是反复出现的问题 [[2]]。受这些观察的启发，本提案强调：(i) 建立一个清晰的基准（Benchmark）；(ii) 设定一个明确的“我们的模型”作为改进目标；以及 (iii) 采用更符合实际部署需求的丰富评估体系。

问题陈述 (Problem Statement)

给定一段简短的社交媒体风格文本，我们的目标是分类其是否包含网络霸凌内容。根据数据集的不同，任务可分为：

- **二分类 (Binary):** 霸凌 vs. 非霸凌；或
- **多分类 (Multi-class):** 霸凌类别，如针对性别、种族、宗教、年龄或其他特定群体的骚扰。

本提案侧重于“文本优先”的方法，同时保持设计的可扩展性，以便在未来的迭代中加入多模态信号（图像、用户上下文或交互图谱）。

目标与研究问题 (Objectives and Research Questions)

主要目标

1. 构建一个可复现的网络霸凌检测数据预处理和训练流程。
2. 建立强有力的基线，在同一协议下包含经典机器学习和 Transformer 微调模型。
3. 提出并测试一个改进模型，旨在提高类别不平衡和领域偏移下的鲁棒性。
4. 使用更丰富的评估方法（不仅仅是准确率/精确率/召回率/F1）报告结果，包括校准度和统计检验。

研究问题

1. 当数据划分、调优预算和报告指标受控时，经典 ML 基线与 Transformer 基线相比表现如何？
2. 领域自适应加上不平衡感知训练，是否能提高宏观（Macro）层面的性能并减少少数类霸凌类型的识别失败？
3. 哪些评估视角（AUPRC、校准误差、鲁棒性检查）能比单点指标提供更具可操作性的见解？

相关工作 (Related Work)

早期的网络霸凌检测系统依赖于词汇特征和传统分类器，如逻辑回归（Logistic Regression）和支持向量机（SVM）。较新的方法使用深度神经架构（如循环网络）和上下文语言模型，其中 Transformer 已成为许多文本分类任务的默认起点。BERT [[3]] 和 RoBERTa [[4]] 能够捕捉上下文和长距离依赖关系，通常优于词袋模型，特别是当霸凌线索依赖于短语语境时。

然而，综述强调“更好的模型”并不自动转化为可靠的系统 [[1]]。领域不匹配（平台风格、地区、俚语）会降低性能，且标签不平衡可能导致准确率虚高，而少数类却很难被检测到。领域自适应预训练（在任务微调前继续在领域内文本上进行预训练）是缩小领域差距的一种实用策略 [[5]]。同时，不平衡感知学习方法（如 Focal Loss）通过重新加权困难和代表性不足的样本，在正类稀少时被广泛使用 [[6]]。本提案将这些思想整合到一个连贯的实验计划中：将经典 ML 和 Transformer 微调视为基线，然后测试一个专注于鲁棒性的单一“我们的模型”。

拟议方法 (Proposed Methodology)

图 1 总结了整体工作流程。

数据集与数据准备

我们将从一个公开的网络霸凌数据集开始，该数据集包含简短的帖子以及指示霸凌内容和/或霸凌类型的标签。一种常见的结构是一个占多数的“非霸凌”类和多个占少数的骚扰类别。这符合我们的智慧城市背景，因为面向市民的平台通常包含大量的正常内容，以及一小部分但至关重要的有害互动。

数据准备将遵循一致且有文档记录的协议：

- **数据审计：**检查标签分布、重复项和明显的噪声；定义最终任务的稳定标签映射。
- **归一化：**规范化 URL 和用户提及（@user），处理过多的重复字符，并尽可能标准化 Emoji 表情。




图 1

拟议的网络霸凌检测项目端到端工作流程。

- **分词 (Tokenization):** 为经典 ML 使用 TF-IDF 特征；为 Transformer 基线 and 我们的模型使用子词 (Subword) 分词。
- **数据划分:** 进行分层 (Stratified) 训练/验证/测试划分；如果存在多个数据集，保留一个用于域外 (Out-of-Domain) 评估以近似领域漂移。

为了减少意外的数据泄露，我们将在划分前对近似相同的文本进行去重，并保持清晰的随机种子策略。

基线模型

1. **经典 ML 基线:** 基于 TF-IDF 特征 (单词和字符 n-grams) 训练的逻辑回归和线性 SVM。
2. **Transformer 基线:** 带有标准分类头的微调版 BERT [[3]] 和 RoBERTa [[4]]。

基线模型将共享相同的数据划分，并使用固定的超参数预算进行调优，以保持比较的公平性。

我们的模型 (拟议改进)

我们的模型建立在 Transformer 基线之上，但针对两个实际弱点进行改进：领域不匹配和少数类错误。我们提出以下增强措施：

- a) **领域自适应预训练 (DAPT):** 在微调之前，在领域内语料库（例如与智慧城市服务相关的特定平台或话题文本）上继续进行掩码语言模型（MLM）预训练 [[5]]。目的是在不改变下游任务定义的情况下适应词汇和风格。
- b) **不平衡感知学习:** 应用 Focal-style 重加权或类别平衡权重来强调困难/少数类样本 [[6]]。我们将报告这对少数类召回率和 Macro-F1 的影响。
- c) **鲁棒训练配方:** 基于 Macro-F1 的早停（Early Stopping）、学习率调度，以及简单的数据增强（如随机删除或标点噪声），以降低对微小文本变化的敏感度。

表 1
提案中包含的模型系列。

类别	模型	关键设计
基线	LR / Linear SVM	TF-IDF 特征；训练速度快；权重可解释；强线性基准。
基线	BERT / RoBERTa	带分类头的微调；上下文表征和迁移学习。
我们的模型	DAPT + 不平衡感知 Transformer	继续领域内预训练 + 损失重加权，以提高少数类和领域鲁棒性。

训练协议与实施细节

我们将使用 Python 实现该流程，并对依赖项和配置文件进行版本控制。关键协议决策包括：

- **超参数调优:** 在固定预算下进行网格/随机搜索（所有 Transformer 模型预算相同）。
- **可复现性:** 固定随机种子，记录实验日志，并保存检查点（Checkpoints）。
- **效率报告:** 报告标准硬件设置下的每轮训练时间和推理速度（以反映部署约束）。

这些设计选择是出于对网络霸凌研究中可复现性问题的关注 [[2]]。

评估计划

- 1. **不平衡感知指标:** Macro-F1、Weighted-F1、分层精确率/召回率以及混淆矩阵（关注少数类）。
- 2. **排序/阈值指标:** AUROC 和 AUPRC，并在选定的操作点（例如用于筛查的高召回率点）进行阈值调整 [[1]]。
- 3. **校准度 (Calibration):** 预期校准误差 (ECE) 和可靠性图表，以评估预测概率是否值得信赖。
- 4. **鲁棒性检查:** 在噪声输入（错别字、Emoji、字符刷屏）下的性能，以及（如果可行）跨数据集评估。
- 5. **统计可靠性:** Bootstrap 置信区间和配对显著性检验（如 McNemar 检验）以支持结论 [[7]]。
- 6. **错误分析:** 针对误报/漏报进行定性分析，重点关注少数骚扰类型和歧义语言。

该评估计划旨在提供比单一整体准确率更完整的图景，并更好地与实际审核需求保持一致。

项目时间表与分工 (Project Timeline and Work Allocation)

表 2 基于更新后的小组时间表。图 2 使用周为单位可视化了该计划。

项目时间表与任务分配

本项目遵循自 2026 年 1 月 9 日开始的 15 周计划，符合课程要求。详细阶段与交付成果见表 2，其可视化流程见图 2。

预期成果 (Expected Outcomes)

到项目结束时，我们期望交付：

- 1. 一个清洗后的数据集划分和完全可复现的训练流程（脚本 + 配置文件）。
- 2. 一份基准测试报告，在同一协议下比较统一的基线（经典 ML + Transformer 微调）。
- 3. 我们改进模型的实现，以及展示领域自适应和不平衡感知学习效果的消融研究文档。
- 4. 一个综合评估包，包括 AUPRC/AUROC、校准分析、鲁棒性检查和经统计支持的比较结果。
- 5. 一份适合评分的最终提案 PDF，包含清晰的图表。

表 2

项目进度表 (2026 年 1 月 9 日 – 5 月 3 日)

周次	日期范围	关键任务	交付成果
1–2	1 月 9 日 – 1 月 26 日	团队组建、选题确认及项目范围定义。	选题确认书、团队分工表。
3	1 月 27 日 – 2 月 2 日	深度文献综述、数据集采集与预处理 (清洗/标注)。	文献综述报告、预处理后的数据集。
4	2 月 3 日 – 2 月 9 日	撰写项目开题报告 (1500–2000 字)。	开题报告最终版 (占总分 30%)。
5–6	2 月 10 日 – 2 月 23 日	特征工程；构建并训练基线模型 (LR/SVM)。	基线模型文件、训练日志/报告。
7–9	2 月 24 日 – 3 月 15 日	微调 Transformer 模型 (BERT/RoBERTa)；利用 GPU 进行参数优化。	Transformer 模型、模型对比报告。
10–11	3 月 18 日 – 3 月 29 日	多维度评估、误差分析及伦理/合规性检查。	评估报告、优化方案。
12–13	4 月 1 日 – 4 月 12 日	将开题报告扩展为完整项目报告；通过 Turnitin 查重。	项目最终报告 (占总分 50%)。
14–15	4 月 15 日 – 5 月 3 日	准备演示文稿 (20–30 分钟) 并进行彩排；最终归档。	演示 PPT、归档项目资产 (占总分 20%)。

风险与缓解措施 (Risks and Mitigation)

- **标签不平衡与不稳定的少数类指标:** 我们将报告 Macro-F1 和置信区间，并将基于 AUPRC 而非仅基于准确率来调整阈值。
- **领域漂移:** 如果无法获得域外数据集，我们将尽可能利用基于话题或时间的划分来模拟漂移，并报告其影响。
- **可复现性问题:** 我们将遵循可复现性建议 [[2]]，保持固定种子、版本化依赖和实验日志。

结论 (Conclusion)

本提案旨在为智慧城市数字环境构建一个实用且可复现的网络霸凌检测流程。通过将所有比较系统视为基线并强调单一改进的“我们的模型”，实验结构变得更加清晰且易于评分。我们也承诺采用更丰富的评估方法，以更好地反映不平衡和不断变化的在线语言的




图 2
项目生命周期甘特图（从启动到最终演示）。

现实情况。由此产生的成果将支持课程评估，并为未来向多模态或平台集成的智慧城市审核工具扩展奠定基础。

参考文献 (References)

- [1] Elsafoury, F., Salama, M., & Elaziz, M. A. (2021). When the Timeline Meets the Pipeline: A Survey on Automated Cyberbullying Detection. *IEEE Access*, 9, 103541–103562.
- [2] Emmery, C., Verhoeven, B., De Pauw, G., Daelemans, W., & Hoste, V. (2021). Current limitations in cyberbullying detection: On evaluation criteria, reproducibility, and data scarcity. *Language Resources and Evaluation*, 55, 1301–1338.
- [3] Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In *Proceedings of NAACL-HLT* (pp. 4171–4186).
- [4] Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L., & Stoyanov, V. (2019). RoBERTa: A Robustly Optimized BERT Pretraining Approach. *arXiv:1907.11692*.
- [5] Gururangan, S., Marasović, A., Swayamdipta, S., Lo, K., Beltagy, I., Downey, D., & Smith, N. A. (2020). Don't Stop Pretraining: Adapt Language Models to Domains and Tasks. In *Proceedings of ACL* (pp. 8342–8360).
- [6] Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal Loss for Dense Object Detection. In *Proceedings of ICCV* (pp. 2980–2988).
- [7] Dror, R., Baumer, G., Shlomov, S., & Reichart, R. (2018). The Hitchhiker's Guide to Testing Statistical Significance in Natural Language Processing. In *Proceedings of ACL* (pp. 1383–1392).